Curso de Extensão
SITS

Análise e Classificação de Séries Temporais com SITS

Aula 4: Random Forest, Classificação e Validação — O Mapa Final



Pesquisador: Alarcon Matos de Oliveira
Divisão de Observação da Terra e Geoinformática (DIOTG) | Pesquisador – SERE II/INPE

Objetivo: Transformar amostras brutas em um mapa de uso e cobertura da terra validado.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

O Plano de Voo: Teoria e Prática

TEORIA (30 min): Os Fundamentos

- **Classificação Temporal:** Trajetórias vs. Pixels.
- **Random Forest:** Ensemble learning no espaço-tempo.
- **Probability Cube:** Mapeando a incerteza estatística.
- **Suavização Bayesiana:** Consistência e redução de ruído.
- **Validação Crítica:** Matriz de confusão e métricas.

PRÁTICA (1h30): A Execução em R

- **Preparação:** Estruturando o dataset de treino.
- **Treinamento:** Modelagem com `sits_train()`.
- **Classificação:** Inferência com `sits_classify()`.
- **Filtros Espaciais:** Refinamento com `sits_smooth()`.
- **Geração & Avaliação:** Rótulos finais e acurácia.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

O Pipeline SITS: Da Amostra ao Mapa



MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

1. Classificação de Séries Temporais: O Desafio

CONCEITO



A Mudança de Paradigma: Ao invés de classificar um pixel estático, analisamos uma trajetória temporal

A Entrada: 23 observações anuais capturando a assinatura fenológica.

A Saída: Rótulos categóricos discretos.

PRÁTICA

```
# Preparação dos dados tabulares de treinamento
Amostras estruturadas requerem:
longitude, latitude, start_date, end_date, e o label.
```

2. O Motor Preditivo: Random Forest





Maioria: Pastagem
Votação 2 a 1

Ensemble Learning: Cria uma "floresta" de dezenas de árvores independentes.

Votação Majoritária: A classe final é decidida pela maioria.

Robustez Natural: Altamente resistente a outliers e ruído atmosférico.

Foco nas Inflexões: Identifica pontos críticos de mudança fenológica.

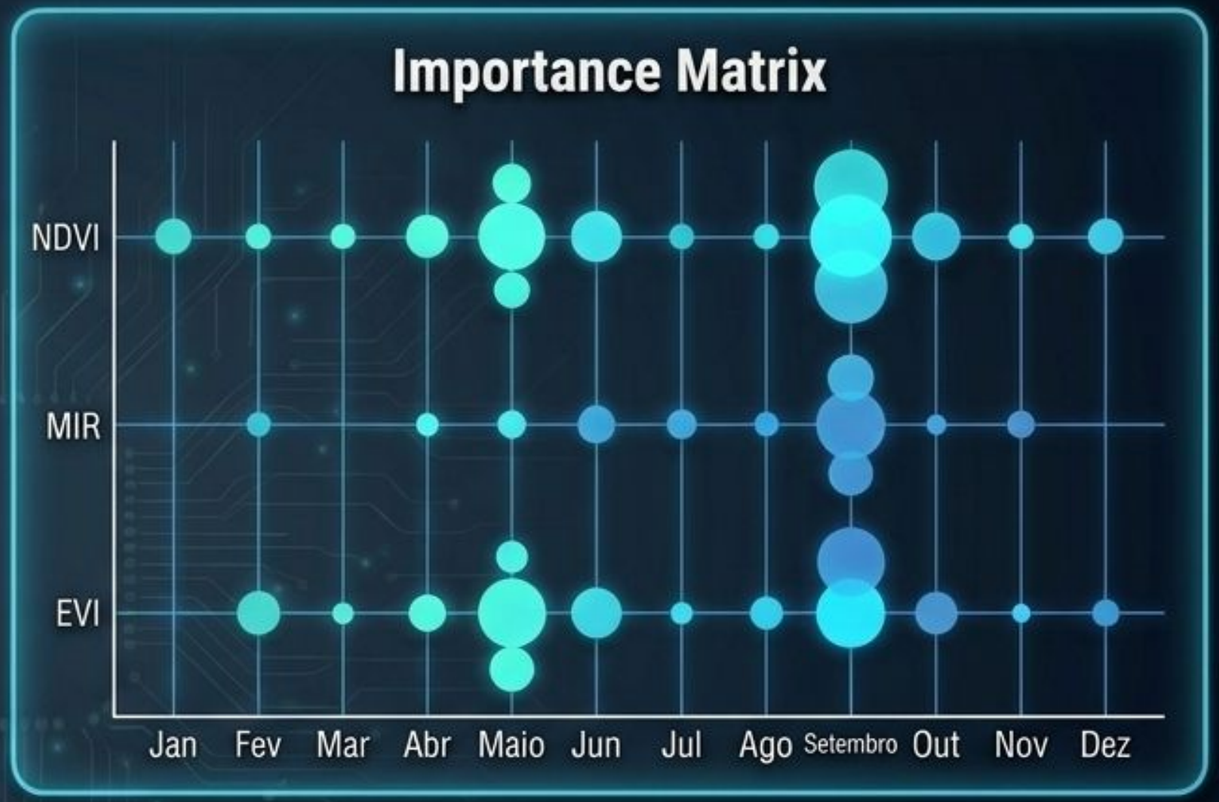
MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

Prática: Treinamento Supervisionado

TERMINA

```
# Treinamento com 100 árvores de decisão
modelo_rf <- sits_train(
  samples    = amostras_preparadas,
  ml_method = sits_rfor(num_trees = 100)
)

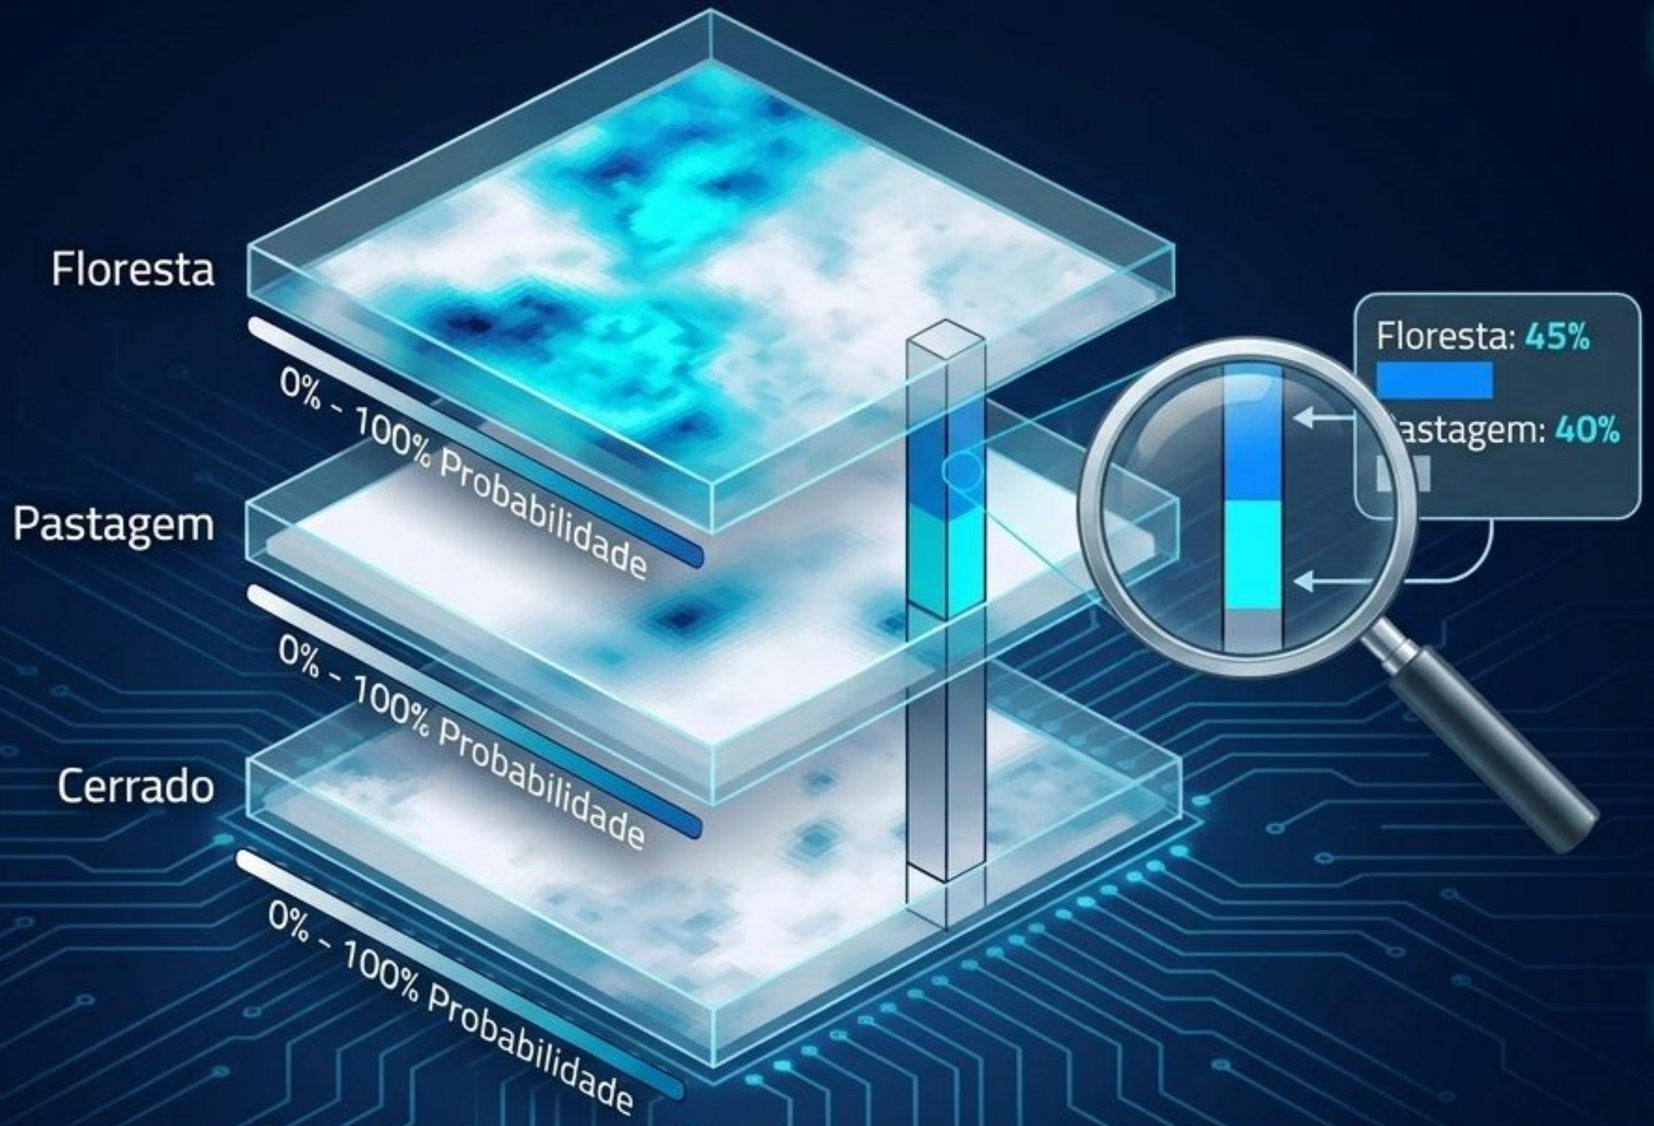
# Visualizando as variáveis mais importantes
plot(modelo_rf)
```



Conectando Amostras e IA: sits_train() ensina os padrões temporais.

Dica Analítica: O gráfico de importância revela quais bandas e datas foram críticas para separar as classes.

3. O Cubo de Probabilidades e a Incerteza



Medindo a Confusão

- **Além do Mapa Fixo:** A saída bruta não é um mapa, mas um cubo onde cada camada representa a probabilidade (0 a 1) de um pixel pertencer a uma classe.
- **Entropia:** Mede a dispersão. Alta entropia = modelo dividido.
- **Margem:** Diferença entre as duas classes mais prováveis. Margens estreitas (45% vs 40%) indicam zonas críticas ou falta de amostras.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

Prática: Inferência e Mapeamento da Incerteza

TERMINA

```
# 1. Gerando o Probability Cube
cubo_probs <- sits_classify(
  data       = cubo_dados,
  ml_model   = modelo_rf,
  multicores = 4
)
# 2. Calculando a Incerteza (Entropia)
cubo_incerteza <- sits_uncertainty(
  cube = cubo_probs, type = 'entropy'
)
```



- **Processamento Paralelo:** sits_classify() processa milhões de pixels simultaneamente.
- **Active Learning:** O mapa de incerteza mostra geograficamente onde é necessário coletar novas amostras de treinamento.

ENTROPIA: INCERTEZA DA CLASSIFICAÇÃO

Sensoriamento remoto • interpretação das probabilidades por pixel

O QUE A ENTROPIA MEDE?

A entropia, conceito associado ao trabalho clássico de Claude Shannon, quantifica como as probabilidades das classes se distribuem para cada pixel.

ENTROPIA BAIXA

Probabilidades concentradas em uma classe. O classificador demonstra maior confiança na previsão.

MAIOR CONFIANÇA

ENTROPIA ALTA

Probabilidades distribuídas entre várias classes. A previsão é mais incerta.

MAIOR INCERTEZA

```
s2_cube_uncert <- sits_uncertainty(
    ...  # calcular a incerteza do cubo
```

PADRÃO ESPACIAL DA ENTROPIA

O mapa permite localizar áreas com diferentes níveis de incerteza.



LEITURA ANALÍTICA

Use a entropia para identificar onde o modelo está mais seguro — e onde a classificação merece cautela.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

4. Pós-Processamento: Suavização Bayesiana



O Problema (Ruído Pixel-a-Pixel)

- Algoritmos temporais analisam pixels isolados, gerando ruído devido à mistura espectral (ex: um pixel de soja numa floresta densa).

A Solução (Consistência Espacial)

- O SITS assume priori espacial. A matemática Bayesiana ajusta a probabilidade do pixel baseada na vizinhança, corrigindo incertezas.

Prática: Suavização e Geração do Mapa Final

TERMINA

```
# 1. Aplicando o Suavizador Bayesiano
cubo_suavizado <- sits_smooth(
  cube        = cubo_probs,
  window_size = 5
)
# 2. Extraindo o Rótulo Dominante
mapa_final <- sits_label_classification(
  cube = cubo_suavizado
)
plot(mapa_final)
```

- **sits_smooth()** utiliza uma janela móvel para recalcular probabilidades.
- **sits_label_classification()** crava o rótulo final.



MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

5. Validação: A Matemática da Confiança

Um mapa só é útil se for confiável. Necessitamos de métricas baseadas em dados de teste independentes.

	Métrica	O que mede?	Quando focar nela?
	Matriz de Confusão	Cruzamento entre a predição do modelo e a verdade de campo.	Para entender a “fricção” e os limites entre classes.
	Acurácia Global	Percentual total de acertos no mapa inteiro.	Visão geral, mas perigosa em classes desbalanceadas.
	Acurácia por Classe	Erros de Omissão (Produtor) e Comissão (Usuário).	Para garantir a detecção de classes raras.
	F1-Score	Média harmônica entre precisão e recall.	A “métrica de ouro” para avaliar classes difíceis e minoritárias.

Dissecando a Matriz de Confusão



Acertos Absolutos

A diagonal principal mostra onde a predição do modelo concorda perfeitamente com a verdade de campo.

Zonas de Confusão Fenológica

Alta confusão entre classes agrícolas (ex: Fallow_Cotton vs Soy_Cotton) indica assinaturas temporais quase idênticas.

Ação Requerida: Adicionar índices espectrais ou limpar amostras.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO

Prática: Medindo a Acurácia

Terminal

```
# Avaliação de acurácia com
dados independentes
acuracia <- sits_accuracy("
  data     = amostras_teste,
  ml_model = modelo_rf
")

# Imprime a Matriz de Confusão
e F1-Score
summary(acuracia)
```

Console Output

```
Accuracy Summary:
Overall Accuracy: 0.92
Kappa Statistic: 0.89
--------------------------------
Class     | F1-Score | Prod. Acc
Floresta  | 0.95     | 0.96
Cerrado   | 0.88     | 0.85
Soja      | 0.91     | 0.93
```

Importante: As amostras de teste nunca devem ter sido vistas pelo Random Forest durante o treinamento.

Interpretação Crítica: O Papel do Pesquisador

O código rodou e o mapa foi gerado. Como interpretar os resultados criticamente?



Semântica das Classes

As classes fazem sentido? Se a matriz confunde Savanna com Savanna_Parkland, a resolução do sensor é suficiente para capturar essa nuance? Considere fundir classes.



Viés Geográfico

Onde está o erro? Se os erros não são aleatórios e se concentram em uma região específica, suas amostras não capturaram a heterogeneidade daquela área.



Limitações Inerentes

Fronteiras naturais difusas, persistência de nuvens e ruído no sensor sempre gerarão erro. Assuma e documente a incerteza estatística com transparência.

Missão Cumprida: Do Dado Bruto ao Conhecimento

Checklist

Resumo da Nossa Jornada (Aulas 1 a 4):

- [✓] Construímos Cubos de Dados (SITS, BDC).
- [✓] Extraímos e analisamos Séries Temporais.
- [✓] Refinamos amostras com Índices e SOM.
- [✓] Aula 4: Treinamos modelos de Machine Learning, medimos incertezas, aplicamos suavização Bayesiana e geramos mapas validados.

Pesquisador
Alarcon Matos de Oliveira | INPE - DIOTG

SITS: Observação da Terra impulsionada por Big Data e Inteligência Artificial.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO